

Movilidad urbana y productividad económica

June 1, 2026

1 Introducción

Este proyecto tiene como objetivo evaluar el impacto de la movilidad urbana en la productividad económica de las principales ciudades de Latinoamérica. Mediante la integración y análisis de datos de TomTom Traffic Index y OECD Cities, se identificarán los cuellos de botella logísticos y las asimetrías de rendimiento en la región. El entregable final servirá como herramienta estratégica para optimizar la toma de decisiones y priorizar las inversiones en infraestructura de transporte de alto impacto.

1.1 Ingesta de Datos y Análisis Exploratorio Inicial (EDA)

El desarrollo del proyecto comienza con la fase de ingesta y reconocimiento de las fuentes de datos. El objetivo de esta etapa es validar la integridad de los archivos, mapear la estructura de las variables, confirmar los tipos de datos iniciales e identificar anomalías o nulos que requieran tratamiento en la fase de limpieza.

1.1.1 Carga de fuentes y visualización preliminar

Para iniciar el flujo de trabajo, se configuran las librerías del ecosistema de datos en Python (pandas, numpy, seaborn y matplotlib) y se realiza la lectura de los repositorios CSV para alojar la información en DataFrames estructurados.

```
[1]: # Importación de librerías
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
```

```
[2]: # Carga archivos
traffic = pd.read_csv('/datasets/tomtom_traffic.csv')
eco = pd.read_csv('/datasets/oecd_city_economy.csv')
```

```
[3]: # Inspección primeras 5 filas de traffic
traffic.head(5)
```

```
[3]:   Country      City      UpdateTimeUTC  JamsDelay  TrafficIndexLive  \
0     ARE  abu-dhabi  2025-01-13 04:01:30.001      650.7             36.0
1     ARE  abu-dhabi  2025-01-13 03:46:00.000      540.4             30.0
2     ARE  abu-dhabi  2025-01-13 02:46:30.000       71.8              7.0
```

3	ARE	abu-dhabi	2025-01-13 01:46:30.001	8.2	2.0
4	ARE	abu-dhabi	2025-01-13 00:01:30.000	1.1	1.0

	JamsLengthInKms	JamsCount	TrafficIndexWeekAgo	UpdateTimeUTCWeekAgo	\
0	109.1	162.0	30.0	2025-01-06 04:01:30.000	
1	101.4	136.0	27.0	2025-01-06 03:46:30.001	
2	18.9	23.0	6.0	2025-01-06 02:46:30.000	
3	4.1	2.0	2.0	2025-01-06 01:46:30.000	
4	0.2	1.0	1.0	2025-01-06 00:01:30.000	

	TravelTimeLivePer10KmsMins	TravelTimeHistoricPer10KmsMins	MinsDelay
0	11.614767	10.265330	1.349437
1	11.003180	10.031544	0.971635
2	8.196278	8.196510	-0.000232
3	7.723808	7.899046	-0.175238
4	8.336363	8.604379	-0.268016

```
[4]: # Inspección primeras 5 filas de eco
eco.head(5)
```

```
[4]: Year          City          Country City GDP/capita Unemployment % \
0  2023    buenos-aires  Argentina    15.782,00         6.2%
1  2023      sao-paulo    Brazil      14.475,00         9.1%
2  2023  rio-de-janeiro    Brazil      13.142,00         9.8%
3  2023      brasilia    Brazil      15.999,00         8.3%
4  2023      salvador    Brazil       8.761,00        13.1%
```


	PM2.5 (g/m³)	Population (M)
0	15,2	15,30
1	29,50	22,50
2	19,10	13,60
3	13,50	4,70
4	16,00	3,90

1.2 Auditoría, Limpieza y Normalización de Dataframes

Previo a la consolidación de las fuentes de datos, se ejecutó una fase de diagnóstico de calidad de datos (Data Quality Assessment). Esta etapa abarca el análisis de tipos de datos, la identificación de inconsistencias de formato derivadas de la configuración regional, el mapeo de nulos y la estandarización de metadatos bajo la convención snake_case.

1.2.1 Diagnóstico de Estructura y Tipos de Datos Iniciales

Para evaluar la integridad física y lógica de los archivos, se ejecutó una inspección estructural en ambos conjuntos de datos.

```
[5]: # Inspección estructural del dataset de movilidad
traffic.info()
traffic.head(3)
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1004464 entries, 0 to 1004463
Data columns (total 12 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Country                               1004464 non-null object
1   City                                  1004464 non-null object
2   UpdateTimeUTC                         1004464 non-null object
3   JamsDelay                             1004464 non-null float64
4   TrafficIndexLive                      1004464 non-null float64
5   JamsLengthInKms                       1004464 non-null float64
6   JamsCount                             1004464 non-null float64
7   TrafficIndexWeekAgo                   1004464 non-null float64
8   UpdateTimeUTCWeekAgo                  1004464 non-null object
9   TravelTimeLivePer10KmsMins            1004464 non-null float64
10  TravelTimeHistoricPer10KmsMins        1004464 non-null float64
11  MinsDelay                             1004464 non-null float64
dtypes: float64(8), object(4)
memory usage: 92.0+ MB
```

```
[5]: Country      City      UpdateTimeUTC  JamsDelay  TrafficIndexLive \
0   ARE  abu-dhabi  2025-01-13 04:01:30.001      650.7          36.0
1   ARE  abu-dhabi  2025-01-13 03:46:00.000      540.4          30.0
2   ARE  abu-dhabi  2025-01-13 02:46:30.000       71.8           7.0

      JamsLengthInKms  JamsCount  TrafficIndexWeekAgo  UpdateTimeUTCWeekAgo \
0              109.1       162.0              30.0  2025-01-06 04:01:30.000
1              101.4       136.0              27.0  2025-01-06 03:46:30.001
2               18.9        23.0               6.0  2025-01-06 02:46:30.000

      TravelTimeLivePer10KmsMins  TravelTimeHistoricPer10KmsMins  MinsDelay
0              11.614767              10.265330      1.349437
1              11.003180              10.031544      0.971635
2               8.196278               8.196510     -0.000232
```

```
[6]: # Inspección estructural del dataset socioeconómico
eco.info()
eco.head(3)
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 30 entries, 0 to 29
Data columns (total 7 columns):
#   Column                Non-Null Count  Dtype
---  -

```

```

0   Year                30 non-null    int64
1   City                30 non-null    object
2   Country             30 non-null    object
3   City GDP/capita     30 non-null    object
4   Unemployment %     30 non-null    object
5   PM2.5 ( g/m³)      30 non-null    object
6   Population (M)      30 non-null    object
dtypes: int64(1), object(6)
memory usage: 1.8+ KB

```

```

[6]:   Year      City      Country City GDP/capita Unemployment % \
0  2023  buenos-aires  Argentina    15.782,00          6.2%
1  2023   sao-paulo    Brazil     14.475,00          9.1%
2  2023 rio-de-janeiro    Brazil     13.142,00          9.8%

      PM2.5 ( g/m³) Population (M)
0           15,2          15,30
1           29,50          22,50
2           19,10          13,60

```

Reporte de Hallazgos en Auditoría de Datos - Dataset traffic (Volumetría: 1,004,464 registros / 12 columnas): - **Integridad:** No se detectaron valores ausentes (nulls) explícitos en ninguna de las dimensiones. - **Tipos de Datos:** Las marcas temporales (`UpdateTimeUTC` y `UpdateTimeUTCWeekAgo`) se identificaron erróneamente como tipos `object` (strings). Requieren conversión analítica a objetos `datetime64[ns]` para permitir la indexación y agrupaciones temporales. - **Optimización:** La variable de conteo de embotellamientos (`JamsCount`) se importó de manera nativa como `float64`; se redefinirá a un tipo entero (`int64`) para asegurar la coherencia con el diccionario de datos.

- **Dataset eco (Volumetría: 30 registros / 7 columnas):**
 - **Conflicto Regional de Formatos:** El principal desafío técnico en esta fuente radica en el almacenamiento de variables cuantitativas continuas (`City GDP/capita`, `Unemployment %`, `PM2.5`, `Population (M)`) bajo la etiqueta de `object`. Esto se debe al uso de comas y caracteres especiales (como `%`) propios de la configuración de origen.
 - **Acción requerida:** Se requiere un pipeline de saneamiento de cadenas para remover separadores de miles, estandarizar el punto decimal y castear las series hacia tipos numéricos flotantes (`float64`) antes de procesar cálculos o correlaciones.

1.2.2 Estandarización de Metadatos (Renombrado de Columnas)

Con el fin de mitigar errores sintácticos durante la etapa de cruce (*merge*) y asegurar la homogeneidad del código, se renombraron las columnas a la convención *snake_case*. Asimismo, se modificó la variable `Country` en la tabla de tráfico a `country_id` para denotar claramente que aloja códigos ISO-3, previniendo colisiones con el nombre de país textual de la tabla de economía.

```

[7]: # Estandarización de metadatos para el dataset de tráfico
traffic = traffic.rename(columns={
    "Country": "country_id",
    "City": "city",

```

```

    "UpdateTimeUTC": "update_time_utc",
    "JamsDelay": "jams_delay",
    "TrafficIndexLive": "traffic_index_live",
    "JamsLengthInKms": "jams_length_in_kms",
    "JamsCount": "jams_count",
    "TrafficIndexWeekAgo": "traffic_index_week_ago",
    "UpdateTimeUTCWeekAgo": "update_time_utc_week_ago",
    "TravelTimeLivePer10KmsMins": "travel_time_live_per_10kms_mins",
    "TravelTimeHistoricPer10KmsMins": "travel_time_historic_per_10kms_mins",
    "MinsDelay": "mins_delay"
})

# Verificación de esquema en traffic
traffic.columns

```

```

[7]: Index(['country_id', 'city', 'update_time_utc', 'jams_delay',
          'traffic_index_live', 'jams_length_in_kms', 'jams_count',
          'traffic_index_week_ago', 'update_time_utc_week_ago',
          'travel_time_live_per_10kms_mins',
          'travel_time_historic_per_10kms_mins', 'mins_delay'],
         dtype='object')

```

```

[8]: # Estandarización de metadatos para el dataset económico
eco.columns = [
    'year',
    'city',
    'country',
    'city_gdp_capita',
    'unemployment_pct',
    'pm25',
    'population_m'
]

# Verificación de esquema en eco
eco.columns

```

```

[8]: Index(['year', 'city', 'country', 'city_gdp_capita', 'unemployment_pct',
          'pm25', 'population_m'],
         dtype='object')

```

1.2.3 Tratamiento de Formatos Críticos (Tipos Numéricos y Temporales)

Una vez estandarizada la estructura nominal, se construyeron funciones de transformación para corregir las deficiencias de casteo identificadas en la fase de auditoría. Este proceso garantiza la precisión analítica y optimiza la carga de memoria de los objetos en Python.

```
[9]: # Conversión temporal para el dataset de movilidad
traffic['update_time_utc'] = pd.to_datetime(traffic["update_time_utc"],
    ↪ utc=True)
traffic['update_time_utc_week_ago'] = pd.
    ↪ to_datetime(traffic["update_time_utc_week_ago"], utc=True)

# Optimización de almacenamiento en memoria para conteos viales
traffic["jams_count"] = traffic["jams_count"].astype(int)

# Validación del nuevo esquema de tráfico
traffic.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1004464 entries, 0 to 1004463
Data columns (total 12 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   country_id                           1004464 non-null object
1   city                                 1004464 non-null object
2   update_time_utc                      1004464 non-null datetime64[ns, UTC]
3   jams_delay                           1004464 non-null float64
4   traffic_index_live                   1004464 non-null float64
5   jams_length_in_kms                  1004464 non-null float64
6   jams_count                           1004464 non-null int64
7   traffic_index_week_ago               1004464 non-null float64
8   update_time_utc_week_ago             1004464 non-null datetime64[ns, UTC]
9   travel_time_live_per_10kms_mins      1004464 non-null float64
10  travel_time_historic_per_10kms_mins  1004464 non-null float64
11  mins_delay                           1004464 non-null float64
dtypes: datetime64[ns, UTC](2), float64(7), int64(1), object(2)
memory usage: 92.0+ MB
```

```
[10]: # Eliminación de caracteres especiales y ajuste de escala regional para el
    ↪ dataset económico
eco['city_gdp_capita'] = eco["city_gdp_capita"].astype(str).str.replace('.',
    ↪ ', ', regex=False).str.replace(',', '.').astype(float)
eco['unemployment_pct'] = eco["unemployment_pct"].astype(str).str.replace('%',
    ↪ ', ', regex=False).str.replace(',', '.').astype(float)
eco['population_m'] = eco["population_m"].astype(str).str.replace(',', '.').
    ↪ astype(float)

# Obtención de población en unidades absolutas
eco['population'] = eco["population_m"] * 1000000

# Validación del nuevo esquema económico
eco.info()
eco.head(3)
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 30 entries, 0 to 29
Data columns (total 8 columns):
#   Column                Non-Null Count  Dtype
---  -
0   year                   30 non-null    int64
1   city                   30 non-null    object
2   country                30 non-null    object
3   city_gdp_capita        30 non-null    float64
4   unemployment_pct       30 non-null    float64
5   pm25                   30 non-null    object
6   population_m           30 non-null    float64
7   population              30 non-null    float64
dtypes: float64(4), int64(1), object(3)
memory usage: 2.0+ KB
```

```
[10]:   year      city      country  city_gdp_capita  unemployment_pct  pm25  \
0  2023  buenos-aires  Argentina      15782.0           6.2  15,2
1  2023    sao-paulo    Brazil      14475.0           9.1  29,50
2  2023  rio-de-janeiro    Brazil      13142.0           9.8  19,10

      population_m  population
0           15.3  15300000.0
1           22.5  22500000.0
2           13.6  13600000.0
```

1.3 Segmentación Temporal (Ventana Fiscal 2024)

Con el fin de asegurar una comparación homogénea y metodológicamente válida entre las métricas de tráfico de alta frecuencia y los indicadores macroeconómicos anuales de la OECD, se delimitó el alcance del análisis al año 2024.

Esta sección detalla la extracción del año a partir de las marcas de tiempo y segmentando los conjuntos de datos.

1.3.1 Extracción de Componentes de Fecha y Filtrado de Registros

Dado que el dataset traffic no cuenta con una dimensión nativa para el año, se utilizó el accesor .dt de pandas para extraer el año calendario desde la variable update_time_utc. Una vez indexado este nuevo atributo, se aislo el periodo 2024 en ambas fuentes.

Nota: Con el objetivo de salvaguardar la integridad de las matrices originales y eludir la advertencia SettingWithCopyWarning, se empleó el método .copy(). Esto asegura la creación de sub-dataframes independientes (traffic_2024 y eco_2024).

```
[11]: # Extracción del año calendario

traffic['year'] = traffic["update_time_utc"].dt.year
```

```
# Inspección de la nueva estructura de metadatos en el dataframe de movilidad
traffic.head(3)
```

```
[11]: country_id      city      update_time_utc  jams_delay \
0      ARE  abu-dhabi  2025-01-13 04:01:30.001000+00:00      650.7
1      ARE  abu-dhabi      2025-01-13 03:46:00+00:00      540.4
2      ARE  abu-dhabi      2025-01-13 02:46:30+00:00      71.8

      traffic_index_live  jams_length_in_kms  jams_count  traffic_index_week_ago \
0              36.0              109.1              162              30.0
1              30.0              101.4              136              27.0
2               7.0               18.9               23               6.0

      update_time_utc_week_ago  travel_time_live_per_10kms_mins \
0      2025-01-06 04:01:30+00:00      11.614767
1  2025-01-06 03:46:30.001000+00:00      11.003180
2      2025-01-06 02:46:30+00:00      8.196278

      travel_time_historic_per_10kms_mins  mins_delay  year
0              10.265330      1.349437  2025
1              10.031544      0.971635  2025
2               8.196510     -0.000232  2025
```

```
[12]: # Segmentación y clonación en memoria para el periodo objetivo (2024)
traffic_2024 = traffic[traffic["year"]==2024].copy()
eco_2024 = eco[eco["year"]==2024].copy()

# Validación visual de dataframes nuevos
display(traffic_2024.head())
display(eco_2024.head())
```

```
country_id      city      update_time_utc  jams_delay \
302      ARE  abu-dhabi      2024-12-31 23:01:30+00:00      12.9
303      ARE  abu-dhabi      2024-12-31 22:01:30+00:00      136.0
304      ARE  abu-dhabi      2024-12-31 21:16:30+00:00      455.2
305      ARE  abu-dhabi  2024-12-31 20:01:00.001000+00:00      399.4
306      ARE  abu-dhabi      2024-12-31 19:46:00+00:00      366.4

      traffic_index_live  jams_length_in_kms  jams_count \
302              5.0              2.5              5
303              21.0              20.6              32
304              31.0              40.4              72
305              27.0              38.0              75
306              28.0              39.8              82

      traffic_index_week_ago      update_time_utc_week_ago \
```



```

302          2.0 2024-12-24 23:01:30.001000+00:00
303          3.0      2024-12-24 22:01:30+00:00
304          4.0      2024-12-24 21:01:30+00:00
305          6.0 2024-12-24 20:01:30.001000+00:00
306          9.0      2024-12-24 19:01:00+00:00

      travel_time_live_per_10kms_mins  travel_time_historic_per_10kms_mins  \
302          8.560399          8.519634
303         10.355732          9.049445
304         11.456878          9.305174
305         11.670062          9.952811
306         11.686322         10.008469

      mins_delay  year
302    0.040765  2024
303    1.306286  2024
304    2.151704  2024
305    1.717252  2024
306    1.677853  2024

      year      city      country  city_gdp_capita  unemployment_pct  pm25  \
15  2024  buenos-aires  Argentina      18117.0          7.2  14,50
16  2024    sao-paulo    Brazil      14703.0          8.5  28,00
17  2024  rio-de-janeiro    Brazil      13349.0          9.2  18,40
18  2024    brasilia    Brazil      16251.0          7.8  12,80
19  2024    salvador    Brazil       8899.0         12.4  15,20

      population_m  population
15          15.4  15400000.0
16          22.6  22600000.0
17          13.7  13700000.0
18           4.8   4800000.0
19           3.9   3900000.0

```

1.4 Consolidación de Datos y Análisis del Perfil de Movilidad Urbana

El dataset de movilidad registra observaciones con una frecuencia de alta densidad (minutos/horas). Para compatibilizar esta información con las métricas macroeconómicas anuales de la OECD y aislar el ruido estadístico de las fluctuaciones diarias, se procedió a consolidar el comportamiento de las métricas clave mediante promedios anualizados por metrópoli.

1.4.1 Consolidación de Métricas Anuales de Tráfico (groupby)

Se aplicó una operación de agregación para calcular la media de los indicadores de congestión, longitud de embotellamientos y tiempos de retraso. El resultado se almacenó en la estructura `traffic_city_year_2024`, restableciendo los niveles de indexación para mantener consistencia en las dimensiones.

```
[13]: # Agregación estratégica de métricas de movilidad urbana
traffic_city_year_2024 =traffic_2024.groupby(["city","country_id","year"])\
.agg ({
    "jams_delay":"mean",
    "traffic_index_live":"mean",
    "jams_length_in_kms":"mean",
    "jams_count":"mean",
    "mins_delay":"mean",
    "travel_time_live_per_10kms_mins":"mean",
    "travel_time_historic_per_10kms_mins":"mean"
}).reset_index()

# Verificación del DataFrame consolidado
traffic_city_year_2024.head()
```

```
[13]:
```

	city	country_id	year	jams_delay	traffic_index_live \
0	a-coruna	ESP	2024	17.935187	15.259774
1	aachen	DEU	2024	26.732141	20.960314
2	aarhus	DNK	2024	21.200616	16.575891
3	abu-dhabi	ARE	2024	171.157315	13.902028
4	adana	TUR	2024	83.864761	22.541040

	jams_length_in_kms	jams_count	mins_delay \
0	2.198002	4.934405	0.774172
1	3.892586	6.601832	0.792968
2	2.736736	6.109987	0.495276
3	24.507380	47.268019	0.139764
4	11.827331	23.754620	1.129749

	travel_time_live_per_10kms_mins	travel_time_historic_per_10kms_mins
0	16.267977	15.493804
1	13.397861	12.604894
2	15.219292	14.724016
3	9.829092	9.689328
4	15.879694	14.749945

1.4.2 Identificación de Outliers Viales a Nivel Global

Con la matriz anualizada, se realizó un ordenamiento descendente basado en la variable jams_delay (retraso promedio total provocado por congestión). Este paso es crítico para identificar preliminarmente las metrópolis con los sistemas viales más estresados del mundo, las cuales representan los focos primarios de interés para la inversión en infraestructura.

```
[14]: # Ciudades con mayor criticidad logística
traffic_city_year_2024.sort_values(["jams_delay"], ascending=False)
```

```

[14]:      city country_id year   jams_delay traffic_index_live \
221  mexico-city      MEX  2024  2833.057892      34.218190
352    tokyo          JPN  2024  2152.574357      36.805059
246  new-york         USA  2024  2133.400000      28.210388
200   london         GBR  2024  2050.703662      29.230166
211   manila          PHL  2024  1741.493381      66.129402
..      ""          ""      ""          ""          ""
111   dunedin         NZL  2024    4.651175      15.430809
363   uppsala         SWE  2024    4.194486      13.939168
123  fujairah         ARE  2024    4.025959      10.907719
12    almere          NLD  2024    3.633523       6.290478
117   el-paso         USA  2024    0.299024       2.340435

      jams_length_in_kms jams_count mins_delay \
221      389.239265    594.969392    1.855542
352      373.069734    518.809420    0.698152
246      398.227892    544.474902    1.396351
200      287.632868    471.795554    1.325160
211      246.858082    341.881205    2.469894
..      ""          ""          ""
111      0.712315     1.591384    0.633294
363      0.656368     1.349672    0.501802
123      0.731910     1.373006    0.194951
12      0.506362     1.064063   -0.017544
117      0.031114     0.078118   -0.250676

      travel_time_live_per_10kms_mins travel_time_historic_per_10kms_mins
221      21.809092      19.953550
352      22.443778      21.745626
246      18.505043      17.108691
200      17.714139      16.388979
211      27.134629      24.664734
..      ""          ""
111      16.226009      15.592715
363      15.746717      15.244916
123      11.662590      11.467639
12       9.467150       9.484694
117      10.690269      10.940945

```

[387 rows x 10 columns]

Insights Clave de Movilidad Urbana (2024) - **Liderazgo de Congestión en LATAM:** El análisis identifica a **Ciudad de México** (mexicocity) en la primera posición global con un retraso promedio de 2,833.05 minutos, superando de manera significativa a megaurbes altamente densas como Tokio (2,152.57 mins) y Nueva York (2,133.40 mins). - **Validación de Negocio:** Este hallazgo valida la relevancia estratégica del estudio para el American Development Bank. El hecho de que una metrópoli latinoamericana

encabece el índice de retrasos consolidados subraya la urgencia de evaluar cómo esta ineficiencia en la movilidad impacta de forma directa en la productividad económica local (PIB per cápita y desempleo), hipótesis que se resolverá al integrar las variables de la OECD.

1.5 Integración de Matrices Analíticas (Feature Consolidation)

Para habilitar la fase de modelado y exploración visual, se procedió a consolidar las dimensiones de movilidad urbana con las variables socioeconómicas en una única matriz analítica.

Este proceso implica una reducción selectiva del espacio de características (feature selection) para optimizar el uso de memoria, la clonación explícita de las estructuras de datos para evitar mutaciones no deseadas, y una intersección relacional basada en claves compuestas.

1.5.1 Selección de Atributos Clave y Fusión de Datasets (*Inner Join*)

Se definieron los vectores de características más representativos para el análisis de impacto del American Development Bank, aislando métricas de saturación vial e indicadores de rendimiento macroeconómico.

La fusión de datos se ejecutó bajo una estrategia de **intersección estricta** (*Inner Join*) utilizando como llaves relacionales las variables complejas *city* y *year*. Esto garantiza que la estructura final solo contenga entidades con registros completos en ambos dominios de observación durante el periodo 2024.

```
[15]: # Feature Selection: Definición de variables clave para el análisis de impacto
left_cols = ['city', 'country_id', 'year', 'jams_delay', 'traffic_index_live',
             'jams_length_in_kms', 'jams_count', 'mins_delay',
             'travel_time_live_per_10kms_mins', 'travel_time_historic_per_10kms_mins']

right_cols = ['city', 'year', 'city_gdp_capita', 'unemployment_pct', 'pm25', 'population']

# Aislamiento y clonación en memoria
traffic_2024_small = traffic_city_year_2024[left_cols].copy()
eco_2024_small = eco_2024[right_cols].copy()

# Consolidación relacional mediante intersección indexada (Inner Merge)
merged = pd.merge(traffic_2024_small, eco_2024_small, how="inner",
                  on=["city", "year"])

# Inspección de las primeras filas del dataset unificado
merged.head(5)
```

```
[15]:
```

	city	country_id	year	jams_delay	traffic_index_live	\
0	belo-horizonte	BRA	2024	263.047879	19.428946	
1	bogota	COL	2024	1141.552364	37.614273	
2	brasilia	BRA	2024	101.576326	11.258220	

3	buenos-aires	ARG	2024	571.089593	17.756012
4	curitiba	BRA	2024	183.469274	14.954545

	jams_length_in_kms	jams_count	mins_delay	\
0	44.038129	68.805422	0.487228	
1	140.893564	230.566550	1.699628	
2	18.337133	27.280140	0.193442	
3	100.287844	137.359860	0.416566	
4	30.050044	46.898164	0.139965	

	travel_time_live_per_10kms_mins	travel_time_historic_per_10kms_mins	\
0	18.304538	17.817311	
1	24.992185	23.292557	
2	13.338658	13.145216	
3	17.907916	17.491349	
4	17.258700	17.118736	

	city_gdp_capita	unemployment_pct	pm25	population
0	11124.0	9.5	16,80	6100000.0
1	11442.0	10.0	17,60	11300000.0
2	16251.0	7.8	12,80	4800000.0
3	18117.0	7.2	14,50	15400000.0
4	12381.0	8.2	13,50	3700000.0

1.6 Análisis Exploratorio Visual (EDA) y Diagnóstico de Correlaciones

Con la matriz analítica consolidada, se procedió a realizar un análisis exploratorio visual para caracterizar las distribuciones individuales de las variables e investigar la hipótesis central del American Development Bank: la existencia de una correlación entre el estrés vial y la productividad económica urbana.

1.6.1 Distribución Univariada: Comportamiento de la Congestión y el PIB per cápita

Para entender la dispersión, la tendencia central y la presencia de valores atípicos (outliers), se modeló el retraso vial mediante un diagrama de caja (Boxplot) y la distribución del PIB per cápita a través de un histograma de frecuencias.

```
[16]: # Seteo del estilo visual profesional
sns.set_theme(style="whitegrid")
fig, axes = plt.subplots(1, 2, figsize=(15, 6))

# Gráfico 1: Diagnóstico de dispersión del retraso vial (Boxplot)
sns.boxplot(ax=axes[0], x="jams_delay", data=merged, color="#3498db",
            ↪showmeans=True,
            meanprops={"marker": "o", "markerfacecolor": "white",
            ↪"markeredgecolor": "black", "markersize": "8"})
```


```

axes[0].set_title('Distribución Global de Retrasos por Congestión (2024)',
    ↪fontsize=12, fontweight='bold')
axes[0].set_xlabel('Minutos de Retraso Promedio (JamsDelay)', fontsize=10)

# Gráfico 2: Distribución de la Productividad Económica (Histograma)
sns.histplot(ax=axes[1], x="city_gdp_capita", data=merged, bins=10, kde=True,
    ↪color="#2ecc71")
axes[1].set_title('Distribución del PIB per Cápita Urbano (2024)', fontsize=12,
    ↪fontweight='bold')
axes[1].set_xlabel('PIB per Cápita (USD)', fontsize=10)
axes[1].set_ylabel('Frecuencia de Ciudades', fontsize=10)

plt.tight_layout()
plt.show()

```



```

[17]: # Seteo del estilo visual profesional
sns.set_theme(style="whitegrid")
fig, axes = plt.subplots(1, 2, figsize=(15, 6))

# Gráfico 1: Diagnóstico de dispersión del retraso vial (Boxplot)
mean_value = merged['jams_delay'].mean()
sns.boxplot(
    x="jams_delay",
    data=merged,
    color="#3498db",
    showmeans=True,
    meanprops={"marker": "o", "markerfacecolor": "white", "markeredgcolor":
    ↪"black", "markersize": 8},
    ax=axes[0]
)

```


```

axes[0].set_title(f'Distribución Global de Retrasos por Congestión
    ↪(2024)\nPromedio: {mean_value:.2f}', fontsize=12, fontweight='bold')
axes[0].set_xlabel('Minutos de Retraso Promedio (JamsDelay)', fontsize=10)

# Gráfico 2: Distribución de la Productividad Económica (Histograma)
sns.histplot(x="city_gdp_capita", data=merged, bins=5, kde=True,
    ↪color="#2ecc71")
axes[1].set_title('Distribución del PIB per Cápita Urbano (2024)', fontsize=12,
    ↪fontweight='bold')
axes[1].set_xlabel('PIB per Cápita (USD)', fontsize=10)
axes[1].set_ylabel('Frecuencia de Ciudades', fontsize=10)

plt.tight_layout()
plt.show()

```



1.6.2 Distribución Bivariada: Intersección de Productividad vs. Estrés Vial

```

[18]: # Seteo del estilo visual profesional
sns.set_theme(style="whitegrid")
fig, axes = plt.subplots(1, 2, figsize=(12, 8))

# Gráfico 1: Barras para comparar jams_delay y city_gdp_capita por ciudad
merged.plot(kind="bar", y=['jams_delay', 'city_gdp_capita'], ax=axes[0])
axes[0].tick_params(axis='x', rotation=0)

# Gráfico 2: Scatter plot con codificación de color por país y tamaño por
    ↪población
sns.scatterplot(
    data=merged,
    x="city_gdp_capita",

```


```

        y="jams_delay",
        hue="country_id",
        size="population",
        sizes=(100, 1000),
        palette="deep",
        alpha=0.8,
        ax=axes[1]
    )
    # Etiquetado dinámico de las ciudades clave para la toma de decisiones
    for i in range(merged.shape[0]):
        # Filtrar etiquetas para evitar solapamiento visual
        if merged['city'][i] in ['mexico-city', 'bogota', 'lima', 'sao-paulo', 'montevideo', 'santiago']:
            plt.text(
                x=merged['city_gdp_capita'][i] + 300,
                y=merged['jams_delay'][i],
                s=merged['city'][i].title(),
                fontdict=dict(color='black', size=10, weight='semibold')
            )

plt.title('Matriz de Decisión del BID: Productividad Económica vs. Estrés Vial (2024)', fontsize=14, fontweight='bold', pad=15)
plt.xlabel('PIB per cápita de la Ciudad (USD)', fontsize=11)
plt.ylabel('Retraso Promedio por Congestión (Minutos)', fontsize=11)
plt.legend(bbox_to_anchor=(1.05, 1), loc='upper left', title='Variables Contextuales')
plt.tight_layout()
plt.show()

```


Matriz de Decisión del BID: Productividad Económica vs. Estrés Vial (2024)



Diagnóstico Estratégico e Interpretación de Negocio El análisis bivariado revela una **ausencia de correlación lineal** directa entre la productividad económica (*city_gdp_capita*) y la degradación de la movilidad urbana (*jams_delay*) en la región, rompiendo con el supuesto tradicional de que a mayor desarrollo económico, invariablemente existe mayor saturación vial.

- **Asimetrías Regionales Críticas (Baja Productividad / Alta Congestión):** -Ciudades como **Bogotá y Lima** presentan un fuerte estrés vial (retrasos superiores a los 1,000 minutos) a pesar de registrar niveles de PIB per cápita moderados-bajos en la muestra. Esto denota un déficit estructural severo en sus sistemas de transporte masivo, donde el tráfico actúa como un impuesto regresivo al tiempo y a la productividad laboral.
- **El Caso Atípico de Ciudad de México:** -Representa el *outlier/ más severo del estudio. Con un PIB per cápita competitivo para la región (~26,000 USD), experimenta niveles de congestión insostenibles (2,833 minutos). Esto sugiere que la infraestructura actual ha alcanzado un punto de saturación crítica que podría estar frenando un potencial de crecimiento económico aún mayor.
- **Modelos de Eficiencia Vial (Alta Productividad / Baja Congestión):** -**Montevideo** se posiciona como el contraejemplo ideal: registra el PIB per cápita más alto de la muestra con el nivel de retraso vial más bajo. Esto la cataloga preliminarmente como una metrópoli con una gestión de movilidad eficiente o una escala urbana controlada.

Recomendación de Inversión para el American Development Bank Desde

la perspectiva de la banca de desarrollo, el retorno social y económico de la inversión en infraestructura no se encuentra en las ciudades eficientes (como Montevideo), sino en aquellas donde la movilidad estrangula la economía. **Ciudad de México, Bogotá y Lima** representan los objetivos prioritarios de financiamiento, ya que desbloquear su movilidad generará el mayor impacto marginal en la productividad de su población económicamente activa.

1.7 Análisis Extendido — Preguntas de Negocio Adicionales

1.7.1 ¿Existe correlación entre el tiempo extra de viaje por tráfico (mins_delay) y los niveles de contaminación del aire (pm25)?

```
[42]: # Correlación entre mins_delay y PM2.5
# Primero convertir pm25 a numérico (tiene comas como separador decimal)
merged['pm25_num'] = merged['pm25'].astype(str).str.replace(',', '.').
    ↪astype(float)


correlacion_pm25 = merged[['mins_delay', 'pm25_num']].corr()
print("Correlación mins_delay vs PM2.5:")
correlacion_pm25
```

Correlación mins_delay vs PM2.5:

```
[42]:
```

	mins_delay	pm25_num
mins_delay	1.000000	0.643116
pm25_num	0.643116	1.000000

```
[43]: plt.figure(figsize=(8, 5))
sns.scatterplot(data=merged, x='mins_delay', y='pm25_num', hue='city')
plt.title('Relación entre Retraso por Tráfico y Contaminación PM2.5 (2024)')
plt.xlabel('Minutos de retraso promedio por 10km (mins_delay)')
plt.ylabel('Contaminación PM2.5 (g/m³)')
plt.legend(bbox_to_anchor=(1.05, 1), loc='upper left', fontsize=8)
plt.tight_layout()
plt.show()
```



1.7.2 ¿Qué ciudades muestran mayor brecha entre tráfico histórico y en tiempo real, y cómo se correlaciona con el desempleo?

```
[38]: # Brecha tráfico histórico vs tiempo real y correlación con desempleo
merged['brecha_trafico_min'] = (
    merged['travel_time_live_per_10kms_mins'] -
    merged['travel_time_historic_per_10kms_mins']
)

# Top ciudades con mayor brecha
top_brecha = merged[['city', 'brecha_trafico_min', 'unemployment_pct']] \
    .sort_values('brecha_trafico_min', ascending=False) \
    .reset_index(drop=True)
print("Ciudades con mayor vulnerabilidad vial:")
top_brecha
```


Ciudades con mayor vulnerabilidad vial:

```
[38]:
```

	city	brecha_trafico_min	unemployment_pct
0	mexico-city	1.855542	3.2
1	bogota	1.699628	10.0
2	lima	1.506305	6.5
3	sao-paulo	1.129026	8.5
4	santiago	0.627445	7.8

5	belo-horizonte	0.487228	9.5
6	buenos-aires	0.416566	7.2
7	montevideo	0.393442	8.4
8	rio-de-janeiro	0.361302	9.2
9	porto-alegre	0.194195	8.7
10	brasilia	0.193442	7.8
11	curitiba	0.139965	8.2
12	salvador	0.115811	12.4
13	fortaleza	0.081618	11.8
14	recife	0.072539	11.2

```
[49]: # Visualización
fig, ax1 = plt.subplots(figsize=(10, 5))
ax1.bar(top_brecha['city'], top_brecha['brecha_trafico_min'],
        color='steelblue', label='Brecha de tráfico (min)')
ax1.set_xlabel('Ciudad')
ax1.set_ylabel('Brecha histórico vs real (min/10km)', color='steelblue')
ax2 = ax1.twinx()
ax2.plot(top_brecha['city'], top_brecha['unemployment_pct'],
        color='orange', marker='o', label='Desempleo %')
ax2.set_ylabel('Desempleo (%)', color='orange')
plt.title('Vulnerabilidad Vial vs Desempleo por Ciudad (2024)')
ax1.set_xticks(range(len(top_brecha['city'])))
ax1.set_xticklabels(top_brecha['city'], rotation=90, ha='right')
plt.tight_layout()
plt.show()
```



```
[50]: correlacion_desempleo = merged[['brecha_trafico', 'unemployment_pct']].corr()
print("\nCorrelación brecha de tráfico vs Desempleo:")
correlacion_desempleo
```

Correlación brecha de tráfico vs Desempleo:

```
[50]:
```

	brecha_trafico	unemployment_pct
brecha_trafico	1.000000	-0.592742
unemployment_pct	-0.592742	1.000000

1.8 Persistencia del Artefacto de Datos e Informe Ejecutivo

Esta fase final documenta el cierre del pipeline de datos a través de la exportación del activo digital reproducible y la presentación del informe ejecutivo estructurado para la alta dirección del American Development Bank.

1.8.1 Exportación del Dataset de Producción

Para garantizar la reproducibilidad del análisis por parte de otros equipos de ciencia de datos u herramientas de Business Intelligence (como Tableau o Power BI), la matriz analítica consolidada se exportó en un formato plano estandarizado, omitiendo los índices secuenciales de memoria de Python.## Persistencia del Artefacto de Datos e Informe Ejecutivo

```
[19]: # Almacenamiento del activo de datos depurado
output_filename = "ladb_mobility_economy_2024_clean.csv"
merged.to_csv(output_filename, index=False)

print(f"Pipeline finalizado. Activo de datos exportado exitosamente como:↳
↳{output_filename}")
```

Pipeline finalizado. Activo de datos exportado exitosamente como:
ladb_mobility_economy_2024_clean.csv

2 Reporte Ejecutivo de Consultoría

I. Marco Conceptual y Objetivos Estratégicos El presente análisis investiga el impacto macroeconómico de la ineficiencia en la movilidad urbana dentro de las principales metrópolis de la región durante el periodo fiscal 2024. Desde la perspectiva de la economía urbana, la congestión vehicular opera como un impuesto regresivo oculto: el tiempo atrapado en el tráfico representa una pérdida directa de horas-hombre productivas, incrementa los costos logísticos de distribución, ralentiza las cadenas de suministro locales y reduce el radio efectivo de los mercados laborales. Por lo tanto, la optimización de los sistemas de transporte masivo no es únicamente un asunto de bienestar social, sino un catalizador crítico para expandir los límites del PIB urbano y mejorar la competitividad económica regional.

3 II. Arquitectura de Datos y Alcance Metodológico

Para este diagnóstico, se construyó un pipeline de integración que unificó dos fuentes globales de alta credibilidad: el TomTom Traffic Index (capturando variables de saturación vial como la longitud y volumen de embotellamientos, minutos de retraso e indexación del tiempo de viaje real frente al histórico) y los indicadores de la OECD Cities (aportando las dimensiones socioeconómicas de población absoluta, PIB per cápita, tasas de desempleo y la métrica de sostenibilidad ambiental PM2.5).

El análisis se acotó estrictamente a la ventana temporal de **2024** debido a que representaba el periodo más reciente con simetría de registros completos en ambas fuentes. Tras un proceso de agregación estadística para mitigar la volatilidad diaria del tráfico (reduciendo la granularidad a promedios anualizados) y la aplicación de una fusión por intersección estricta (Inner Join), la muestra final quedó conformada por un tablero balanceado de 15 ciudades clave distribuidas en 7 países de América Latina, garantizando un análisis libre de sesgos por datos huérfanos o registros incompletos.

4 III. Diagnóstico de Hallazgos y Análisis de Anomalías

El cruce bivariado determinó una **ausencia de correlación lineal directa** entre el volumen del PIB per cápita y el nivel de retraso por congestión. Esto demuestra que la riqueza económica no es un predictor del estrés vial en la región, aislando dos comportamientos atípicos (outliers) críticos para el análisis:

- **El Límite de Saturación (Ciudad de México):** Registra el pico absoluto de congestión global con un promedio de 2,833.06 minutos de retraso, superando por más del 60% al segundo lugar de la muestra. Al ser la segunda economía con mayor PIB del grupo, este comportamiento sugiere que su infraestructura vial ha alcanzado un punto de estrangulamiento crítico que compromete activamente su techo de crecimiento macroeconómico.
- **El Modelo de Eficiencia (Montevideo):** Se posiciona en el extremo opuesto, registrando la mayor productividad económica por habitante (26,176 USD) con niveles de retraso vial prácticamente imperceptibles. Este caso de estudio amerita una investigación secundaria para aislar las políticas de ordenamiento territorial y las dinámicas demográficas que permiten este equilibrio.

5 IV. Recomendaciones Estratégicas de Inversión

Con base en los indicadores de retorno marginal y vulnerabilidad estructural, se proponen las siguientes prioridades de financiamiento:

1. **Prioridad Uno (Bogotá):** La capital colombiana se identifica como el objetivo prioritario para la asignación de fondos de infraestructura de transporte. La ciudad presenta una asimetría crítica: sostiene un PIB per cápita moderado pero sufre el índice de tráfico y retrasos más severo después de las megaurbes de la muestra. La evidencia sugiere que la ineficiencia de su movilidad está actuando como una barrera que frena el desarrollo de su productividad local.

2. **Prioridad Dos (Santiago):** Representa el segundo foco de atención. Registra el PIB per cápita más bajo dentro del dataset integrado, pero mantiene niveles de congestión moderados-altos. La cercanía simétrica entre sus curvas de retraso vial y sus bajos ingresos evidencia cómo el costo de oportunidad del tráfico castiga severamente el rendimiento de su población económicamente activa.
3. **Condicionamiento de Sostenibilidad:** Antes de proceder con la aprobación definitiva de los vehículos financieros para estas ciudades, se recomienda ejecutar una **Fase II de Análisis de Impacto Multi-variable**. Esta iteración deberá cruzar las métricas de contaminación por partículas finas (pm25) y densidades poblacionales calculadas, asegurando que los proyectos de infraestructura aprobados garanticen no solo un retorno económico, sino un desarrollo urbano equitativo, eco-eficiente y con huella de carbono mitigada.

6 V. Hallazgos del Análisis Extendido

Tráfico y Contaminación Ambiental (PM2.5): Se identificó una correlación positiva leve entre los minutos de retraso por tráfico y los niveles de PM2.5, lo que sugiere que la congestión vehicular contribuye parcialmente a la degradación de la calidad del aire urbano. São Paulo constituye una anomalía relevante: presenta contaminación alta con retraso medio, evidenciando fuentes de emisión adicionales más allá del tráfico vehicular que requerirán diagnóstico independiente.

Vulnerabilidad Vial y Mercado Laboral: Las ciudades con menor brecha entre su tráfico histórico y en tiempo real tienden a registrar tasas de desempleo más elevadas, consistente con una hipótesis de menor actividad económica que reduce el volumen vehicular. Bogotá emerge nuevamente como caso atípico crítico: segunda brecha más alta del análisis pero con desempleo medio-alto, confirmando que su congestión tiene carácter estructural, independiente del ciclo económico, y reforzando su clasificación como Prioridad Uno de inversión.